

# Adaptive MCMC

Johannes Nägele

7. Mai 2022

- 1 Einführung und Intuition
- 2 Adaptives Metropolis-Hastings
- 3 Andere adaptive MCMC-Algorithmen
- 4 Allgemeine Resultate

# Problemstellung I

Grundsätzlich liefern MCMC-Algorithmen wie MH unter relativ schwachen Bedingungen die (gesuchte) Gleichgewichtsverteilung. Problem ist dabei die Konvergenzgeschwindigkeit. Intuitiv (Goldilocks-Prinzip):

- Varianz des proposals zu hoch: Sehr wenige Werte werden gesampled, da die meisten verworfen werden.
- Varianz des proposals zu niedrig: Algorithmus stagniert und passt sich nur sehr langsam der gewünschten Verteilung an, da Zustandsraum langsam durchschritten wird.

# Problemstellung II


- Magische 0.234 unter technischen Annahmen als optimale acceptance rate für normalverteiltes MH, großes  $d$  und u.i.v. Komponenten mit existierender Varianz der target distribution [1]
- Für target distribution ohne u.i.v. ist die Varianz  $\frac{2.38^2}{d} \Sigma_{\pi}$  optimal
- In der Praxis:  $\Sigma_{\pi}$  wird durch mehrere Probeläufe geschätzt

---

[1] Andrew Gelman, Walter R. Gilks und Gareth O. Roberts. „Weak convergence and optimal scaling of random walk Metropolis algorithms“. In: *The annals of applied probability* 7.1 (1997), S. 110–120.

# Simulation

Abbildung 1: MCMC-Simulation für normalverteilte proposals mit  $n = 100000$  und burn-in von 10000. Rot: Proposal bei  $\sigma \in (0.1, 1, 100)$ , blau:  $\text{Cauchy}(0, 1)$



# Idee

- Wähle (endogen) gute Parameter für proposal distribution
- Aber: Prozess möglicherweise keine Markovkette mehr und Existenz sowie Form der stationären Verteilung nicht mehr klar
- Möglicherweise blödsinnige Werte (Varianz)
- Ähnlich zu Markov-Decision Processes

# Adaptives Metropolis-Hastings

Definiere den AM-Algorithmus mit normalverteiltem Kern nach [2].

Wähle für die Zielverteilung  $\pi$  bei  $t = 0$  die Startwerte  $X_0$ ,  $\mu_0$  und  $\Sigma_0$  mit  $\pi(X_0) > 0$  sowie  $\beta_{t+1} = 1/(t+1)$ . Bestimme  $X_n$  mit

**while**  $t < n$  **do**

Ziehe  $X^*$  aus  $Q = \mathcal{N}(X_t, \lambda \Sigma_t)$  und  $\alpha$  aus  $\mathcal{U}([0, 1])$ .

**if**  $\pi(X^*)/\pi(X_t) > \alpha$  **then**

$X_{t+1} \leftarrow X^*$

**else**

$X_{t+1} \leftarrow X_t$

**end**

$\mu_{t+1} \leftarrow \mu_t + \beta_{t+1}(X_{t+1} - \mu_t)$

$\Sigma_{t+1} \leftarrow \Sigma_t + \beta_{t+1}[(X_{t+1} - \mu_t)(X_{t+1} - \mu_t)^T - \Sigma_t]$


**end**

---

[2] [Geof H. Givens und Jennifer A. Hoeting](#). Computational Statistics. New York: John Wiley & Sons, 2012, S. 247–248.


# Simulation mit AM I

**Abbildung 2:** Adaptive MCMC-Simulation für normalverteilte proposals mit  $n = 100000$  und burn-in von 10000. Rot: Proposal bei  $\sigma_0 \in (0.1, 1, 100)$ , blau:  $\text{Cauchy}(0, 1)$


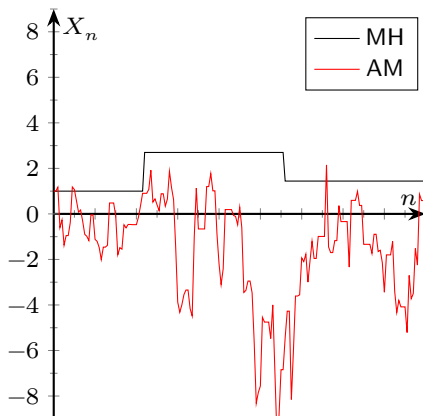




## Simulation mit AM II

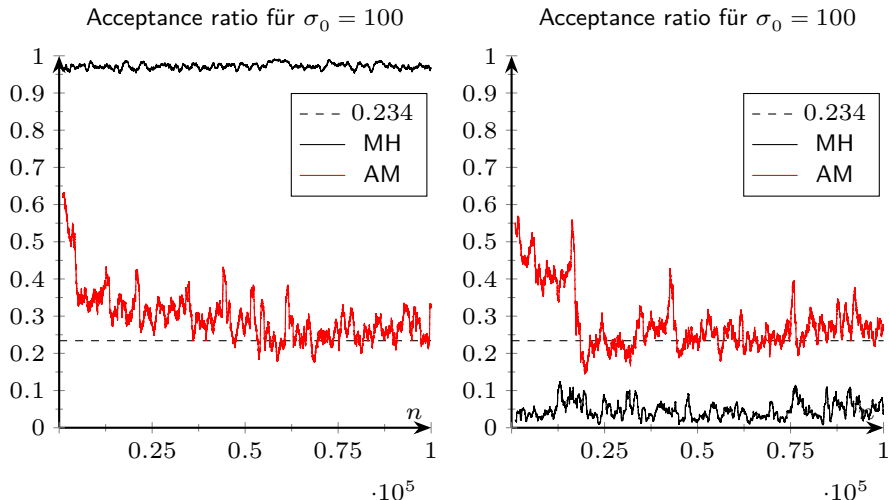
Abbildung 3: Entwicklung von  $\sigma_n$ 

## Simulation mit AM III

Abbildung 4: Gesamplete Werte  $X_n$  für  $n < 200$  $\sigma_0 = 0.1$  $\sigma_0 = 100$ 

## Simulation mit AM IV

Abbildung 5: Moving average der acceptance ratios



# Ein pathologisches Beispiel I

## Beispiel 1

Sei  $X$  eine uniform verteilte Zufallsvariable auf  $\{1, 3, 4\}$  mit Maß  $\pi$  und sei  $Q_i(Y, \cdot)$  eine uniform verteilte Zufallsvariable auf  $\{Y - i, Y + i\}$ ,  $i \in \{1, 2\}$ . Definiere  $R_i(Y, \cdot) = 1/2 \cdot Q_i(Y, \cdot) + 1/2 \cdot \pi(\cdot)$  als transition kernel. Bestimme  $X_n$  mit

**while**  $t < n$  **do**

Ziehe  $X^*$  aus  $R_i(X_t, \cdot)$  und  $\alpha$  aus  $\mathcal{U}([0, 1])$ .

**if**  $[\pi(X^*)/\pi(X_t)]/[R_i(X_t, X^*)/R_i(X^*, X_t)] > \alpha$  **then**

$X_{t+1} \leftarrow X^*$

$i \leftarrow 1$

**else**

$X_{t+1} \leftarrow X_t$

$i \leftarrow 2$

**end**

**end**

# Ein pathologisches Beispiel II

Obiges Beispiel aus [3].

Zu zeigen:  $X_n$  hat invariantes Maß  $\mu \neq \pi$ .

Beweis.

Siehe Tafel. ☐

---

[3] Yves F. Atchadé und Jeffrey S. Rosenthal. „On adaptive Markov chain Monte Carlo algorithms“. In: *Bernoulli* 11.5 (2005), S. 815–828, S. 816–817.

# Ein pathologisches Beispiel III

```

using LinearAlgebra # for eigenvalues
using Pipe:@pipe # for cleaner code

function Q(n, j, i) # variable part of the transition kernel
    return (n-j) in [-i, i] ? 1/2 : 0 # uniform distribution
end

function P(m, n, j,  $\beta$ ) # assumes all values have probability > 0
    i = (m == n) ? 1 : 2
     $\psi$  = (m == n == 1) | (m != n == 4) ? (1- $\beta$ ) : (1- $\beta$ )/2
    return (j == n) ?  $\beta$ *1/3 +  $\psi$  : (1- $\beta$ )*Q(n, j, i) +  $\beta$ *1/3
end

```

# Ein pathologisches Beispiel III

```

β = 1/2 # mixing parameter
state = [1,3,4] # state space
cartesian = Iterators.product(state, state) |>
  collect |> permutedims
transition = zeros(9,9)
# fill the transition matrix
for n in 1:9
  for j in 1:9
    value_n = cartesian[n]
    value_j = cartesian[j]
    transition[n,j] = (value_n[2] == value_j[1]) ?
      P(value_n[1], value_n[2], value_j[2], β) : 0
  end
end
end

```

# Ein pathologisches Beispiel III

```
julia> round.(transition, digits=2)
9×9 Array{Float64,2}:
0.67  0.17  0.17  0.0  0.0  0.0  0.0  0.0  0.0
0.0   0.0   0.0   0.42 0.42 0.17 0.0  0.0  0.0
0.0   0.0   0.0   0.0  0.0  0.0  0.17 0.17 0.67
0.42  0.42  0.17  0.0  0.0  0.0  0.0  0.0  0.0
0.0   0.0   0.0   0.17 0.42 0.42 0.0  0.0  0.0
0.0   0.0   0.0   0.0  0.0  0.0  0.17 0.17 0.67
0.42  0.42  0.17  0.0  0.0  0.0  0.0  0.0  0.0
0.0   0.0   0.0   0.42 0.42 0.17 0.0  0.0  0.0
0.0   0.0   0.0   0.0  0.0  0.0  0.17 0.42 0.42
```



# Ein pathologisches Beispiel III

```

# find eigenvectors
equilibrium = transpose(transition) |> eigvecs |> transpose
# find eigenvector with eigenvalue 1
eig = @pipe transpose(transition) |> eigvals |>
      isapprox(_, 1) |> findfirst(x -> x == true, _)
μ = @pipe equilibrium[eig,:] |>
      convert(Vector{Real}, _) |> transpose
# normalize
μ = μ/sum(μ)

julia> sum(μ[1:3]) # I use Julia btw
0.35166240409207217

```

# Andere adaptive MCMC-Algorithmen

- Adaptiver Metropolis-within-Gibbs-Algorithmus
- Bisher internal MCMC, außerdem (vgl. [4])
  - External MCMC
  - Interacting MCMC
- In der Praxis viele Möglichkeiten (z. B. batches)

---

[4] Atchadé und Rosenthal, „On adaptive Markov chain Monte Carlo algorithms“, S. 1–4.

# Voraussetzungen I

Die nachfolgende Darstellung orientiert sich an [5].

Sei  $X_n$  eine Zufallsvariable auf  $\mathcal{A}$ , die den Zustand des Algorithmus repräsentiert, und  $\theta_n$  eine Zufallsvariable auf dem Parameterraum  $\Theta$ , welche die Wahl der proposal distribution beschreibt,  $n \in \mathbb{N}_0$ .

## Definition

Für  $A_n, B_n$  Zufallsvariablen auf  $\mathcal{A}$  ist  $D_n(A_n, B_n) = \sup_{X \in \mathcal{A}} |P_{A_n} - P_{B_n}|$  die *total variational distance* zwischen  $A_n$  und  $B_n$  zum Zeitpunkt  $n \in \mathbb{N}_0$ .

## Definition

Wir nennen  $X_n$  *ergodisch* bzgl.  $\pi$ , wenn  $\lim_{n \rightarrow \infty} D_n(X_n, \pi) = 0$ .

---

[5] [Krys Latuszynski](#). Adaptive Markov Chain Monte Carlo: Theory, Methodology and Practice [Vortrag EBEB-Meeting]. 2018, S. 53–55.

# Voraussetzungen II

## Definition

Es gilt *simultaneous uniform ergodicity*, wenn

$$\forall \varepsilon > 0 \exists n(\varepsilon) \in \mathbb{N}: \|P_{\theta}^n(X, \cdot) - \pi(\cdot)\| \leq \varepsilon \forall X \in \mathcal{A}, \theta \in \Theta.$$

## Definition

Sei  $A_n = \sup_{X \in \mathcal{A}} \|P_{\theta_n}(X, \cdot) - P_{\theta_{n+1}}(X, \cdot)\|$ , dann hat der Prozess *diminishing adaptation*, wenn  $\lim_{n \rightarrow \infty} A_n = 0$ .

## Definition

Sei  $M_{\varepsilon}(x, \theta) = \inf\{n \geq 1: \|P_{\theta}^n(x, \cdot) - \pi(\cdot)\| \leq \varepsilon\}$ , dann gilt *containment*, wenn  $\{M_{\varepsilon}(X_n, \gamma_n)\}_{n=0}^{\infty}$  für alle  $\varepsilon > 0$  in Wahrscheinlichkeit beschränkt ist.

# Resultate I

In [6] werden folgende zentrale Resultate gezeigt.

## Theorem 1

Gelten die Bedingungen containment und diminishing adaptation, dann folgt Ergodizität der Markovkette.

## Beweis.

Siehe [6], Theorem 2. □

## Theorem 2

Gelten die Bedingungen simultaneous uniform ergodicity und diminishing adaptation, dann folgt Ergodizität der Markovkette.

---

[6] Gareth O. Roberts und Jeffrey S. Rosenthal. „Coupling and Ergodicity of Adaptive Markov Chain Monte Carlo Algorithms“. In: *Journal of Applied Probability* 44.2 (2007), S. 458–475.

# Resultate II

Beweis.

Siehe [6], Theorem 1. □

## Theorem 3

Gelte simultaneous uniform ergodicity sowie diminishing adaptation und sei  $g: \Omega \rightarrow \mathbb{R}$  eine beschränkte messbare Funktion, dann folgt unter beliebigen Startwerten

$$\frac{1}{n} \sum_{i=1}^n g(X_i) \rightarrow \pi(g).$$

Beweis.

Siehe [6], Theorem 5. □

# Anwendung auf AM

## Bemerkung

Der AM-Algorithmus erfüllt die Voraussetzungen von Theorem und .

## Beweis.

Simultaneous uniform ergodicity klar, diminishing adaptation nicht. ☐

Für diminishing adaptation siehe [7].

---






[7] Heikki Haario, Eero Saksman und Johanna Tamminen. „An adaptive Metropolis algorithm“. In: *Bernoulli* 7.2 (2001), S. 223–242, S. 230–231.

# Zusammenfassung

- AMCMC-Algorithmen bieten einfachen Weg, um Konvergenz zu beschleunigen
- Per se können viele MCMC-Algorithmen auf diese Weise beschleunigt werden, aber Vorsicht ist trotzdem geboten
- Theoretisch vor allem Ergodensätze, LLNs und Konvergenzgeschwindigkeit (scaling)



# References

-  Atchadé, Yves F. und Jeffrey S. Rosenthal. „On adaptive Markov chain Monte Carlo algorithms“. In: *Bernoulli* 11.5 (2005), S. 815–828.
-  Gelman, Andrew, Walter R. Gilks und Gareth O. Roberts. „Weak convergence and optimal scaling of random walk Metropolis algorithms“. In: *The annals of applied probability* 7.1 (1997), S. 110–120.
-  Givens, Geof H. und Jennifer A. Hoeting. Computational Statistics. New York: John Wiley & Sons, 2012.
-  Haario, Heikki, Eero Saksman und Johanna Tamminen. „An adaptive Metropolis algorithm“. In: *Bernoulli* 7.2 (2001), S. 223–242.
-  Latuszynski, Krys. Adaptive Markov Chain Monte Carlo: Theory, Methodology and Practice [Vortrag EBEB-Meeting]. 2018. URL: [https://warwick.ac.uk/fac/sci/statistics/staff/academic-research/latuszynski/adap\\_course\\_rio.pdf](https://warwick.ac.uk/fac/sci/statistics/staff/academic-research/latuszynski/adap_course_rio.pdf).

# References



Roberts, Gareth O. und Jeffrey S. Rosenthal. „Coupling and Ergodicity of Adaptive Markov Chain Monte Carlo Algorithms“. In: *Journal of Applied Probability* 44.2 (2007), S. 458–475.